Churn XAI — Classification Explicable de l'Attrition Client

Projet Challenge 1 — Data Mining, ENSI 2026-2027 — Cas métier : Télécom, Telco Customer Churn (IBM/Kaggle)

Problème métier

Un opérateur télécom souhaite anticiper les résiliations (churn) pour cibler des actions de rétention avant la perte du client. Le modèle doit être performant et explicable : un conseiller doit comprendre pourquoi un client donné est jugé à risque pour choisir le bon levier d'action.

Données

Telco Customer Churn (IBM/Kaggle) : 7 043 clients, 20 variables explicatives (contrat, services souscrits, ancienneté, facturation...) + cible binaire **Churn** (26,5% de résiliations). Téléchargement automatisé via *kagglehub*, avec repli sur import CSV manuel.

Meilleur modèle et résultats

5 modèles comparés (régression logistique, arbre de décision, k-NN, Random Forest, XGBoost) sur un split 80/20 stratifié. La **régression logistique** obtient le meilleur AUC-ROC, à performance quasi égale avec XGBoost — un modèle simple et interprétable suffit sur ce cas.

Modèle	AUC-ROC	PR-AUC	Précision	Rappel	F1
Régression logistique	0.842	0.632	0.657	0.559	0.604
XGBoost	0.833	0.649	0.630	0.505	0.561
Arbre de décision	0.830	0.648	0.635	0.567	0.599
K plus proches voisins	0.822	0.613	0.585	0.564	0.574
Random Forest	0.817	0.606	0.607	0.479	0.535

Explications clés (SHAP / LIME)

Globalement, **tenure** (ancienneté) domine nettement (importance par permutation 0.147 en AUC), suivie de **MonthlyCharges**, **Contract** (type de contrat) et **InternetService** (type de connexion) — un client récent, en contrat mensuel, avec fibre optique, présente le risque de churn le plus élevé. Comparaison SHAP/LIME sur 40 clients du jeu de test, après regroupement des colonnes one-hot par variable d'origine : même signe pour 399/400 contributions, 3,9 variables communes en moyenne dans le top 5, corrélation des rangs médiane 0,77. Les deux méthodes s'accordent donc sur le sens des effets ; l'ordre exact varie légèrement (LIME discrétise les variables continues). Exemple de phrase de synthèse générée automatiquement : *«Ce client a risque de depart faible (probabilite 4.5%), principalement a cause de : tenure (diminue le risque), TotalCharges (augmente le risque), MonthlyCharges (diminue le risque).»*

Recommandations et limites

- Cibler en priorité les clients à faible ancienneté, en contrat mensuel et abonnés à la fibre optique pour des offres de fidélisation (passage à un contrat annuel, remise les premiers mois).
- Le modèle utilise **gender** et **SeniorCitizen** ; leur importance reste faible comparée à tenure/Contract, mais un déploiement réel devrait auditer l'équité du score par sous-groupe avant mise en production.
- Le jeu de données est un échantillon figé (pas de dérive temporelle testée) : les coefficients et importances devront être réévalués périodiquement en production.
- La régression logistique étant quasi aussi performante que XGBoost ici, privilégier le modèle interprétable pour la mise en production tant que l'écart de performance reste négligeable.

Code source, notebook et API : voir le dépôt GitHub du projet (README.md).