Churn XAI — Classification Explicable de l'Attrition Client

Projet Challenge 1 — Data Mining, ENSI 2026-2027 — Cas métier : Télécom, Telco Customer Churn (IBM/Kaggle)

Problème métier

Un opérateur télécom souhaite anticiper les résiliations (churn) pour cibler des actions de rétention avant la perte du client. Le modèle doit être performant et explicable : un conseiller doit comprendre pourquoi un client donné est jugé à risque pour choisir le bon levier d'action.

Données

Telco Customer Churn (IBM/Kaggle) : 7 043 clients, 20 variables explicatives (contrat, services souscrits, ancienneté, facturation...) + cible binaire **Churn** (26,5% de résiliations). Téléchargement automatisé via *kagglehub*, avec repli sur import CSV manuel.

Meilleur modèle et résultats

5 modèles comparés (régression logistique, arbre de décision, k-NN, Random Forest, XGBoost) sur un split 80/20 stratifié. La **régression logistique** obtient le meilleur AUC-ROC, à performance quasi égale avec XGBoost — un modèle simple et interprétable suffit sur ce cas.

Modèle	AUC-ROC	PR-AUC	Précision	Rappel	F1
Régression logistique	0.842	0.632	0.657	0.559	0.604
XGBoost	0.833	0.640	0.630	0.505	0.561
Arbre de décision	0.830	0.648	0.535	0.567	0.599
K plus proches voisins	0.822	0.613	0.585	0.564	0.574
Random Forest	0.817	0.606	0.607	0.479	0.535

Explications clés (SHAP / LIME)

Globalement, les trois variables dominantes (importance native, permutation, et SHAP) sont **tenure** (ancienneté), **Contract** (type de contrat) et **InternetService** (type de connexion internet) — un client récent, en contrat mensuel, avec fibre optique, présente le risque de churn le plus élevé. Sur les individus testés, SHAP et LIME s'accordent sur le signe et l'ordre de ces variables, ce qui renforce la confiance dans l'explication locale. Exemple de phrase de synthèse générée automatiquement : *«Ce client a risque de depart faible (probabilite 4.5%), principalement a cause de : tenure (diminue le risque), TotalCharges (augmente le risque), MonthlyCharges (diminue le risque).»*

Recommandations et limites

- Cibler en priorité les clients à faible ancienneté, en contrat mensuel et abonnés à la fibre optique pour des offres de fidélisation (passage à un contrat annuel, remise les premiers mois).
- Le modèle utilise **gender** et **SeniorCitizen** ; leur importance reste faible comparée à tenure/Contract, mais un déploiement réel devrait auditer l'équité du score par sous-groupe avant mise en production.
- Le jeu de données est un échantillon figé (pas de dérive temporelle testée) : les coefficients et importances devront être réévalués périodiquement en production.
- La régression logistique étant quasi aussi performante que XGBoost ici, privilégier le modèle interprétable pour la mise en production tant que l'écart de performance reste négligeable.

Code source, notebook et API : voir le dépôt GitHub du projet (README.md).